

# **Análise e desenvolvimento de algoritmo para reconhecimento e classificação automática da imagética motora baseado no processamento de sinais de EEG.**

A.C.S. Melo<sup>1</sup>, B.M. Vasconcellos<sup>1</sup>, D.I. Taylor<sup>1</sup>, M.E.B. Melo<sup>1</sup>, Y.S.O. Nascimento<sup>1</sup> e W.P. Santos<sup>1</sup>.

<sup>1</sup>Departamento de Engenharia Biomédica, Centro de Tecnologia e Geociências, Universidade Federal de Pernambuco, Recife, Brasil.

***Abstract** — Motor Imagery (IM) is a mental process of imagining oneself performing a motor action without physically executing it. This process generates neural activity patterns that can be detected through electroencephalography (EEG) recordings. Motor imagery EEG signals have specific characteristics, such as event-related desynchronization/synchronization (ERD/ERS) and mu and beta rhythms modulation. These features make motor imagery an important tool for neurorehabilitation, as they can be used to train and stimulate brain plasticity. This project aims to analyze a dataset of eight motor imagery EEG recordings. The data will go through preprocessing steps, including windowing, filtering, and feature extraction. Then, a classification process will be performed using a Random Forest machine learning algorithm with 10, 50, and 100 trees. The results of this study may contribute to the development of more efficient and accurate motor imagery-based rehabilitation techniques.*

***Index Terms** — Motor imagery, electroencephalogram, EEG, signal processing, machine learning, data mining, Python, Weka.*

capazes de extrair e analisar características dos sinais, a partir da identificação de padrões de atividade cerebral associados a diferentes tipos de movimentos mentais.

As aplicabilidades referentes à IM estão diretamente relacionadas ao desenvolvimentos de novas tecnologias assistivas que visam trazer maior independência para pessoas com deficiências motoras. Nesse sentido, o trabalho em questão apresenta a análise dos dados brutos e o processamento para que possa ser utilizado como base para projetos que envolvam machine learning. IM são aplicadas no uso de programas de treinamento de habilidades cognitivas, como navegação espacial, treinamento musical e treinamento de dança. Estudos mostraram que as imagens motoras podem melhorar as habilidades cognitivas, como consciência espacial, memória e criatividade (Olsson et al., 2008)

## **I. INTRODUÇÃO**

### *A. Imagética Motora*

A Imagética Motora (IM) baseia-se na imaginação da ação motora ativa, sem que haja uma execução real desse movimento. A IM costuma ser utilizada para desenvolver habilidades motoras em atividades esportivas, em sessões nas quais o indivíduo se visualiza realizando movimentos precisos e corretos. No entanto, as mesmas regiões cerebrais envolvidas na execução da ação física correspondente são acionadas, e tal estimulação torna-se detectável por meio de técnicas de neuroimagem, como a eletroencefalografia (EEG) e a ressonância magnética funcional (fMRI).

Conforme a revisão sistemática realizada por Sheng et al. (2020), o processamento de sinais de EEG para reconhecimento e classificação automática da imagética motora tem se tornado cada vez mais popular e eficiente. Isso se deve, em parte, ao fato de o EEG captar a atividade elétrica do cérebro em tempo real, o que permite o desenvolvimento de algoritmos de aprendizado de máquina

### *B. Eletroencefalograma (EEG)*

Os sinais bioelétricos podem se apresentar de diferentes formas, e algumas técnicas que podem ser citadas de aquisição são Eletromiografia, Eletrocardiografia e Eletrocorticografia. Além dessas citadas, existe o Eletroencefalograma (EEG), ferramenta de aquisição utilizada neste estudo.

Assim como os demais métodos de aquisição de sinais bioelétricos, o EEG consiste na amostragem bioelétrica de terminações nervosas contidas na cavidade craniana, as quais se originam do córtex cerebral em forma de potenciais sinápticos. Nesse sentido, a atividade elétrica é expressa como uma diferença de potencial entre dois eletrodos, sendo um posicionado na região do córtex e outro de referência. A classificação de sinais de EEG é realizada dividindo em bandas ou ritmos característicos, com frequências específicas, variando entre 0,5 e 100 Hz, conforme a Tabela

Figura 1: Sistema internacional de posicionamento de eletrodos 10-20

1. Para aquisição, os eletrodos são posicionados em locais específicos do couro cabeludo, de acordo com um sistema internacionalmente estabelecido, o 10-20, vide Figura 1. Nesse padrão adotado, são utilizados 21 pontos marcados dividindo o crânio em proporções de 10 ou 20% da medida das distâncias aos pontos de referência.

Frequência (Hz)	Onda
Delta	0,5 a 4
Teta	4 a 8
Alfa	8 a 13
Beta	13 a 22
Gama	22 a 100

Tabela 1: Faixa de frequência de EEG  
Fonte: Carvalho (2008)

### C. Processamento Digital de Sinais Bioelétricos

Processamento digital de Sinais (PDS) é um método de tratamento aplicado a um sinal de tempo discreto através de mecanismos computacionais, e sua ascensão se deu em conjunto ao desenvolvimento de algoritmos para análise de frequências e filtragem de sinais como a transformada de Fourier - FFT, ao passo queurgia a implementação gradual de microprocessadores nos processos de manipulação de sinais.

Para tratamento digital de sinais analógicos, tais como áudio, vídeo ou bioelétricos, faz-se necessária a inclusão de uma etapa de conversão e digitalização, de modo que o sinal passe do espectro contínuo para o tempo discreto. Os dispositivos capazes de realizar essa conversão são os transdutores de sinais, ou os ADC, do inglês *Analog-to-Digital Converter*. O funcionamento básico de um ADC consiste em amostrar o sinal analógico em intervalos de tempo regulares e, em seguida, converter cada amostra em um valor digital correspondente. Esse valor digital pode ser representado em diferentes formatos, como binário, hexadecimal, entre outros. O diagrama de blocos apresentado na figura 1 representa a configuração básica desse dispositivo.





Figura 1: Esquematização do funcionamento de um dispositivo ADC.

Em PDS, a conversão do sinal analógico para digital configura a etapa de aquisição, e em seguida o sinal amostrado deve ser armazenado para início do pré-processamento, cujo objetivo é a extração dos dados brutos para o processamento propriamente dito. Nesta etapa, é comum a utilização de filtros para remoção de ruídos e demais interferências, ou ainda para realçar determinada característica do sinal.

Durante a etapa de processamento, os dados são segmentados e divididos conforme finalidade. Após separação e identificação dos eventos, é possível realizar a extração de características através das técnicas de análise do espectro de frequência, níveis de amplitude, tempo discreto, dentre outras.

Por fim, os sinais são classificados conforme características extraídas dos segmentos para subdivisão em uma ou mais classes, e isso pode ser feito por meio de algoritmos de aprendizado de máquina, uma vez que é possível treinar dados rotulados para identificação de padrões. Em seguida, deve-se organizar os resultados de forma visual para interpretação e análise, seja pela geração de gráficos ou tabelas, de modo claro e objetivo para interpretação do usuário.

Em Engenharia Biomédica, os sinais de estudo caracterizam-se como biosinais, os quais podem ser adquiridos de múltiplas partes do corpo, o que dependerá da finalidade do estudo. O sinal bioelétrico é um sinal exclusivo e de grande importância para os sistemas biomédicos, pois utiliza células excitáveis para identificar e acompanhar as principais funções do sistema que o origina



(COHEN, 2000).

Os sinais bioelétricos podem se apresentar de diferentes formas, e algumas técnicas que podem ser citadas de aquisição são Eletromiografia, Eletrocardiografia e Eletrocorticografia. Além dessas citadas, existe o Eletroencefalograma (EEG), ferramenta de aquisição utilizada neste estudo. Para adquirir e processar sinais de imagética motora (IM)

para EEG envolve uma série de etapas, incluindo colocação de eletrodos, aquisição de sinal, pré-processamento, extração de características e análise. Essas etapas são essenciais para extrair informações significativas dos sinais de EEG e podem ajudar a desenvolver uma interface cérebro-computador eficaz baseada em IM.

#### D. Janelamento temporal

O janelamento de sinais é uma técnica utilizada para dividir o sinal em segmentos menores a fim de otimizar o seu processamento, pois pode aumentar as características espectrais do sinal, o qual pode ser de vários tipos, como biosinais, imagens e áudio. A escolha do tipo de janela temporal a ser utilizada depende do tipo de sinal em questão, e a adoção de determinada técnica muitas vezes consiste na análise experimental do desempenho de cada método [7].

Podemos realizar janelamentos com e sem sobreposição, que é uma técnica que garante que os dados presentes nas extremidades de uma janela não sejam perdidos. Sendo assim, uma parte da janela irá se sobrepor a anterior. Nesse estudo, será utilizado o janelamento com sobreposição.

#### E. Filtros

A filtragem do EEG Signals é uma estratégia importante e é frequentemente usada nos estágios iniciais do processamento de sinais. O objetivo é melhorar a qualidade dos sinais selecionando uma faixa de frequência específica. Os sinais de EEG contêm vários ruídos, isto é, artefatos que não são de interesse da análise, como movimentos oculares involuntários. (Cohen, 2017). É importante que os pesquisadores filtrem dados do EEG, aprimorando ou atenuando frequências de interesse (via filtros) e removendo artefatos que não são do interesse de sua análise. Nesse estudo o filtro que foi utilizado foi o filtro de Butterworth. O filtro Butterworth é um tipo de filtro de processamento de sinal projetado para ter a resposta de frequência mais plana possível (sem ondulações) na banda de passagem e na resposta zero de rolagem na banda de parada. Considerando banda de interesse de análise neste estudo (1Hz até 100Hz), filtros diferentes foram aplicados a cada frequência com duas ordens diferentes do filtro de Butterworth usadas para a frequência da Beta do sinal EEG, resultando em um total de seis ordens de filtros que foram usados neste estudo, conforme a Tabela 2.

Ordem do filtro de Butterworth	Frequência (Hz)
3	1 a 4
5	4 a 8
5	8 a 13
5	13 a 15
8	15 a 32
8	32 a 100

Tabela 2: Bandas de frequência de EEG e as ordens de filtros utilizados.

## II. MATERIAIS E MÉTODOS

### A. Método Proposto

Para o estudo em questão, foi realizado o pré-processamento dos dados da base fornecida utilizando a ferramenta Google Colab, baseada na linguagem Python. O pré-processamento dos dados seguiu 3 etapas: separação do sinal de acordo com a classe, que foi apresentada em uma tabela de acordo com os pontos que caracterizam os blocos de imagética motora, filtragem, utilizando 6 filtros, correspondentes às bandas de frequência do EEG listadas na tabela 2, e janelamento do sinal com uma sobreposição de até 1/3 do tamanho da janela. O processamento dos dados ocorreu com a extração de 29 atributos por janela, os quais são listados na figura 2.

MVAL	Mean Value	WFL	Waveform Length
VAR	Variance	ZCS	Zero Crossings
STD	Standard Deviation	SSC	Slope Sign Changes
RMS	Root Mean Square	MNF	Mean Frequency
AAC	Average Amplitude Change	MDF	Median Frequency
DASDV	Difference Absolute Deviation	MNP	Mean Power
IAV	Integrated Absolute Value	PKF	Peak Frequency
LOGD	Logarithm Detector	PSR	Power Spectrum Ratio
SSI	Simple Square Integral	TTP	Total Power
MAV	Mean Absolute Value	SM1	1st Spectral Moments
MLOGK	Mean Logarithm Kernel	SM2	2nd Spectral Moments
KURT	Kurtosis	SM3	3rd Spectral Moments
MAX	Maximum Amplitude	VCF	Variance of Central Frequency
TM3	Third Moment		
TM4	Fourth Moment		
TMS	Fifth Moment		

Figura 2: Lista de atributos utilizada no estudo.

Após tal processo, a organização dos dados foi feita para que se seguisse a análise de desempenho de alguns algoritmos de aprendizado de máquina para classificação automática dos sinais. Tal organização foi feita com o auxílio do software Weka, que conta com um algoritmo de

seleção de atributos e um conjunto de outros algoritmos de aprendizado de máquina. No Weka, foi realizada a separação dos dados entre dados de treinamento e dados de teste, os primeiros representaram 80% do total e são esses dados que serão utilizados para a criação do modelo de aprendizado de máquina e para a seleção dos atributos. Já os últimos, serão os sinais que simularão o desempenho desse modelo. Após a separação dos dados, foi feita a análise de desempenho dos algoritmos random forest com 10, 50 e 100 árvores utilizando os índices kappa, de sensibilidade, de especificidade e a acurácia.

### B. Base de Dados

O Banco de Dados utilizado foi desenvolvido por estudos realizados por duas equipes de pesquisa da Universidade Federal de Pernambuco (UFPE), Computação Biomédica da UFPE e Grupo de Pesquisa de Neurociência, supervisionados respectivamente pelos Prof. Dr. Wellington Pinheiro Santos e Prof. Dr. Marcelo Cairrão.

O mesmo consiste em oito coletas de EEG, com 29 canais utilizados, de um mesmo indivíduo que realizava a técnica de imagética motora alternada para três classes: mão esquerda, mão direita e pé. Foram gerados 60 blocos de imagética, sendo 20 para cada classe, com uma taxa de amostragem de 256 Hz para o EEG e com uma janela de 8 segundos para cada um, contudo, apenas os 5 segundos finais trazem maior relevância para a análise. O dado bruto foi armazenado em arquivos do tipo .mat, além de uma planilha com marcadores de início e fim para cada um dos blocos de imagética.

### C. Pré-processamento e Extração de Atributos

Os registros de cada sessão de IM foram separados em 60 trials, 20 para cada classe, porém, como os 8 sinais captados em dias diferentes possuem tamanhos diferentes, é de se esperar encontrar classes com um número diferente de trials. Os marcadores de início e finalização de cada trial foram salvos em uma planilha, intitulada “triggers”, posteriormente utilizada para adicionar a classe no sinal. Foi escolhido inicialmente janela de 5s a fim de compactar o sinal em intervalos com informações mais relevantes, e em seguida um janelamento de 500 ms referente ao período de amostragem para sinais de IM, com sobreposição de 125ms, representando 25% da janela em concordância com o método proposto de até 1/3 do seu tamanho.

Após aquisição dos dados, é necessário realizar a visualização em domínio do tempo e frequência, a fim de se entender o comportamento do sinal a ser estudado na etapa de metodologia. Utilizando-se uma frequência de amostragem de 500 Hz, foi gerado o gráfico do primeiro

trial para o primeiro sinal, com os 29 canais, o qual pode ser visualizado nas Figuras 3 e 4 abaixo.




Figura 3: Representação do primeiro trial do sinal 1 para todos os canais no domínio do tempo.




Figura 4: Representação do primeiro trial do sinal 1 para todos os canais no domínio da frequência.

Ao todo foram geradas 4333 janelas, 1443 referentes à mão esquerda, 1450 referentes à mão direita e 1440 referentes aos pés. Cada janela foi submetida a 6 filtros passa-banda de butterworth, caracterizados pela figura 5.

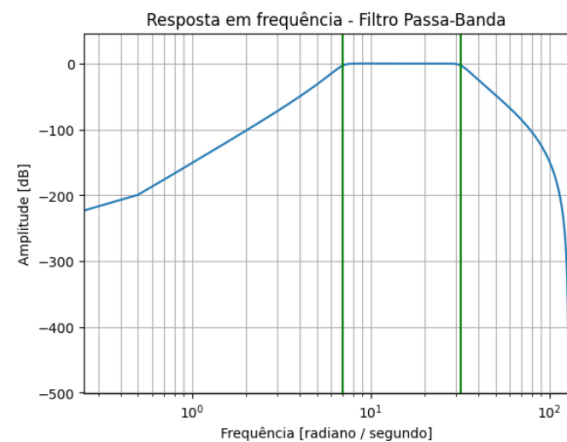


Figura 5: Filtro passa-banda butterworth.

A fim de tornar a banda passante com a menor atenuação possível e maior precisão de corte nas bandas subjacentes, para esses sinais de IM foram utilizados filtros de 3ª ordem para a banda de frequência delta, de 5ª ordem

para as bandas teta, alfa e beta baixa e de 8ª ordem para as bandas beta e gama, pois, desse modo, o comportamento do filtro se aproximou do ideal. É possível observar nas figuras 6 e 7 o comportamento do sinal antes da filtragem em beta(15-32 Hz) e após.




Figura 6: Pré-filtragem em beta.




Figura 7: Após a filtragem em beta.

A etapa de janelamento do sinal consiste em uma técnica importante em EEG para reduzir artefatos e otimizar a precisão da análise do espectro, sobretudo para um sinal cuja característica é ser não-estacionário, tendo suas propriedades estatísticas mutáveis ao longo do tempo. Desse modo, foram determinadas janelas de tempo para identificar as características do sinal de estudo.

Na Figura 8 está representado o sinal janelado em 5 segundos, sem sobreposição. Em seguida, na Figura 9, é apresentada a amostra janelada em 500 ms, com sobreposição de 125 ms.




Figura 8: Janelamento considerando os 5 segundos finais da amostra






Figura 9: Janelamento de 500 ms com 25% (125 ms) de sobreposição

Com o sinal janelado, é possível separar os canais para aplicação dos filtros.

Os atributos foram escolhidos devido ao uso e relevância em processamento digital de sinais (ACHARYA et al., 2018; LI; SUN, 2008; TRAKOOLWILAIWAN et al, 2017; YUAN et al., 2011), estando descritos na Tabela 8. Como no trabalho foram escolhidos os 29 atributos e utilizados 6 filtros para os 27 canais, ao final teremos 4698 atributos por janelamento do sinal. Consequentemente, entrou-se em um entrave, uma vez que o número de atributos foi maior que o número de instâncias, que diminuiu a eficácia do modelo utilizado, além de tornar mais custoso o processamento e a análise dos dados. Também conhecida como o Mal da Dimensionalidade, tal problema foi contornado com a seleção de atributos mais relevantes estatisticamente, utilizando-se do filtro *AttributeSelection* no software Weka, versão 3.8.6, obteve-se a redução do número de atributos para 35.

#### D. Classificação

Visando obter melhores resultado, adotou-se a metodologia de *Supplied Test Set*, para seguir com tal abordagem, fez-se uso do filtro *Resample*, também no Weka, para realização da reamostragem a partir da base com número de atributos reduzidos que foi obtida gerando duas novas: uma com dados de treino, que correspondeu a 80,0%, e outra com dados de teste, correspondendo a 20,0%. Na figura 10 é possível observar uma relação com as configurações finais de cada base.



	Instâncias Totais	Mão Esquerda	Mão Direita	Pé
Dados de Treino	3466	1154	1160	1152
Dados de Teste	866	288	290	288

Figura X: Configurações das bases de Treino e Teste..

A partir das bases geradas, foi realizado o processo de classificação utilizando o algoritmo **RandomForest** com diferentes quantidades de árvores, sendo elas 10, 50 e 100. Esse algoritmo utiliza múltiplas árvores de decisão com a finalidade de alcançar apenas uma solução, baseada na resposta que mais se repetiu como resultado das estruturas de decisão.

Para cada validação foram realizados 30 testes com validação cruzada em 10 folds. As medidas de acurácia, índice Kappa, sensibilidade e especificidade foram observadas, bem como a matriz de confusão, uma vez que tais métricas são de suma importância para avaliação do modelo de classificação.

### III. RESULTADOS E DISCUSSÃO

A avaliação dos resultados obtidos foi feita utilizando 4 parâmetros: acurácia, que representa a porcentagem das instâncias que foram classificadas corretamente, o índice kappa, o qual pode variar de -1 a 1 e indica a concordância entre dois instrumentos de classificação, a sensibilidade, a qual mede a proporção de verdadeiros positivos em relação a todos os casos positivos e a especificidade mede a proporção de verdadeiros negativos em relação a todos os casos de negativos. Na figura 10 é possível observar um resumo dos resultados obtidos.

Classificador	Acurácia	Kappa	Especificidade	Sensibilidade
Random Forest 10 árvores	74.5958 %	0,619	0,873	0,746
Random Forest 50 árvores	79.2148 %	0,6882	0,896	0,792
Random Forest 100 árvores	80.254 %	0,7038	0,901	0,803

Figura 10: Resumo dos resultados obtidos.

Com isso, é possível afirmar que os resultados dos algoritmos de classificação se encontram dentro do esperado, visto que outros trabalhos na área de imagética motora, como [8], [9] e [10] apresentaram, como melhor resultado, uma acurácia de 99,375%, de 71,20% e de 86,85% respectivamente.

Além disso, de acordo com [8], o índice kappa possui a classificação apresentada na figura 11. Portanto, os índices

kappa obtidos nesse estudo considerando todos os algoritmos random forest são classificados como bons.

Kappa	Desempenho
$K \leq 0,2$	Ruim
$0,2 < K \leq 0,4$	Regular
$0,4 < K \leq 0,8$	Bom
$0,8 < K \leq 1$	Excelente

Figura 11: Classificação do índice kappa.

### IV. CONCLUSÃO

Esse estudo teve como objetivo o reconhecimento e classificação de sinais de EEG captados com o voluntário realizando imagética motora da mão direita, esquerda e pé, sendo essas as três classes de estudo, pois a diferenciação de sinais de EEG, que pode ser realizado de forma não invasiva e relativamente barata, propicia o desenvolvimento de tecnologias como a interface cérebro máquina, a qual tem potencial para auxiliar na independência de pessoas que possuam algum déficit motor. Nesse contexto, o trabalho alcançou um resultado satisfatório, com o melhor cenário caracterizado pela adoção do algoritmo de classificação random forest com 100 árvores, que apresentou uma acurácia de, aproximadamente, 80,2 %. Embora o resultado alcançado tenha sido satisfatório, sabe-se que há outras abordagens que poderiam potencializar os resultados, como: reduzir o número de canais, utilizando apenas aqueles relacionados ao córtex motor e adotar apenas a banda beta de frequência, pois é essa a faixa com a maior influência nos sinais de imagética motora. Além disso, outros algoritmos de classificação podem ser testados como o SVM (Support Vector Machine), e, dependendo do seu tempo de processamento, pode ser interessante adotar nesse tipo de problema, pois é um algoritmo robusto para lidar com bases de grandes dimensões e outliers.

### CONFLITOS DE INTERESSE

Não houve nenhum tipo de conflito de interesse entre os autores.

### REFERÊNCIAS

1. SHENG, Xiaoli; LI, Huiling; ZHU, Yali. Automatic recognition of motor imagery EEG signals: A review. Brain science advances, v. 6, n. 1, p. 22-29, 2020.



2. Openheim, A. V. and Schafer, R. W., Discrete-Time Signal Processing, Prentice-Hall, 1989.
3. COHEN, A. Biomedical Signals: Origin and Dynamic Characteristics; Frequency-Domain Analysis. In: BRONZINO, J. D. Biomedical Engineering Handbook. Boca Raton, Florida: CRC Press LLC, 2000.
4. COHEN, M. X. (2017). Where does EEG come from and what does it mean?. *Trends in neurosciences*, 40(4), 208-218. <https://doi.org/10.1016/j.tins.2017.02.004>
5. CARVALHO, L. C. Instrumentação Médico Hospitalar. Barueri: Manole, SP. 2008.
6. CAPERELLI, B. T. Projeto de desenvolvimento de um Sistema multicanal de biotelemetria para detecção de sinais ECG, EEG e EMG. 2007. Dissertação (Mestre em Ciências) – Universidade Federal De Uberlândia, Uberlândia.
7. MACHADO, P. A.; MOECKE, M. Estudos Iniciais do Sistema didático para análise de sinais no domínio da frequência DSA-PC: tipos de janelas temporais.
8. ANDRADE, MARIA KAROLINE DA SILVA. Detecção e classificação de imagética motora utilizando sinais de EEG e aprendizado de máquina 2019.
9. Machado, Gabriel Souza. Análise do desempenho de técnicas de processamento de sinais para uma interface cérebro-computador baseada em imagética motora 2018.
10. Gomes, J. C.; Souza, G. M.; Fragoso, C.; Marques, V.; Brito, C.; Nascimento, Y.; Brito, N. C.; Torcate, A. S.; Santana, M. A.; Moreno, G. M. M.; Santos, W. P. Classificação de imagética motora baseada em EEG utilizando árvores de decisão.
11. Olsson CJ, Jonsson B, Nyberg L. Internal imagery training in active high jumpers. *Scand J Psychol*. 2008 Apr;49(2):133-40. doi: 10.1111/j.1467-9450.2008.00625.x. PMID: 18352982.

**Instituto:** Departamento de Engenharia Biomédica, Centro de Tecnologia e Geociências, Universidade Federal de Pernambuco, Recife, Brasil.  
**Email:** yasmin.samara@ufpe.br

**Autor:** Ana Carolina Soares de Melo.

**Instituto:** Departamento de Engenharia Biomédica, Centro de Tecnologia e Geociências, Universidade Federal de Pernambuco, Recife, Brasil.

**Email:** carolina.soaresm@ufpe.br

**Autor:** Bruno Manhães Vasconcellos.

**Instituto:** Departamento de Engenharia Biomédica, Centro de Tecnologia e Geociências, Universidade Federal de Pernambuco, Recife, Brasil.

**Email:** bruno.manhaesv@ufpe.br

**Autor:** Deidre Imani Taylor.

**Instituto:** Departamento de Engenharia Biomédica, Centro de Tecnologia e Geociências, Universidade Federal de Pernambuco, Recife, Brasil.

**Email:** deidre.taylor@ufpe.br

**Autor:** Maria Eduarda Barros de Melo.

**Instituto:** Departamento de Engenharia Biomédica, Centro de Tecnologia e Geociências, Universidade Federal de Pernambuco, Recife, Brasil.

**Email:** eduarda.bmelo@ufpe.br

**Autor:** Yasmin Samara Oliveira do Nascimento.